(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 119691533 A
(43)申请公布日 2025.03.25

(21)申请号 202510222117.2
(22)申请日 2025.02.27
(71)申请人 贵州大学
地址 550004 贵州省贵阳市花溪区甲秀南路贵州大学西校区
(72)发明人 李传江 谢文辉 钱松荣 韩承林 李少波 张羽 邓承欣
(74)专利代理机构 重庆强大凯创专利代理事务所(普通合伙) 50217
专利代理师 刘永来
(51)Int.Cl.
G06F 18/24(2023.01)
G06F 18/214(2023.01)
G06N 3/0464(2023.01)
G06N 3/0442(2023.01)
G06F 18/27(2023.01)
G06F 17/18(2006.01)
G06F 18/22(2023.01)
G06N 3/048(2023.01)

权利要求书6页 说明书15页 附图4页

(54)发明名称

一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法

(57)摘要

本发明涉及低空飞行器传感器异常检测技术领域,具体为一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法,包括:获取低空飞行器正常飞行状态下的多变量传感器的数据,进行预处理和特征选择,划分训练集和测试集;采用1D CNN、LSTM和KAN,构建CLKAN多元回归模型;根据预设的目标函数,训练并获取最优的模型;采用包含异常样本的测试集测试模型,并根据预测值和实际值计算训练残差和测试残差;采用双向自适应指数加权移动平均法平滑残差序列;根据平滑后的残差计算动态阈值,并通过比较测试残差和动态阈值,进行传感器异常检测。本方案能够在无异常训练样本的情况下,实现低空飞行器传感器多种异常的高精度检测。

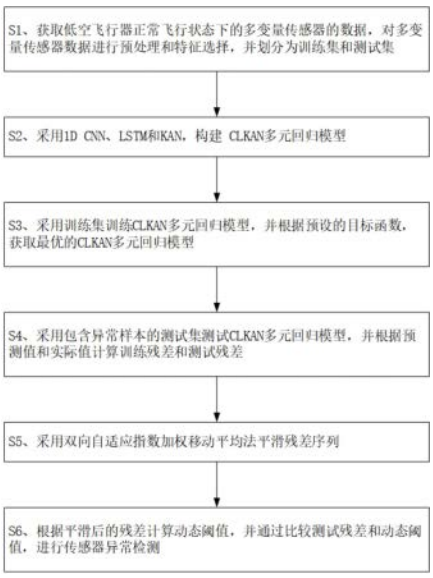

CN 119691533 A

1.一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法,其特征在于,包括如下内容:

S1、获取低空飞行器正常飞行状态下的多变量传感器的数据,对多变量传感器数据进行预处理和特征选择,并划分为训练集和测试集;

S2、采用1D CNN、LSTM和KAN,构建 CLKAN多元回归模型;

S3、采用训练集训练CLKAN多元回归模型,并根据预设的目标函数,获取最优的CLKAN多元回归模型;

S4、采用包含异常样本的测试集测试CLKAN多元回归模型,并根据预测值和实际值计算训练残差和测试残差;

S5、采用双向自适应指数加权移动平均法平滑残差序列;

S6、根据平滑后的残差计算动态阈值,并通过比较测试残差和动态阈值,进行传感器异常检测。

2.根据权利要求1所述的基于CLKAN-RF框架的低空飞行器传感器异常检测方法,其特征在于,所述预处理,包括:数据清洗、归一化和数据重构;

数据清洗:采用线性插值法填充缺失的数据、删除飞行初始阶段不稳定的数据和采用重采样的方法将低空飞行器多变量传感器的数据在时间轴上进行统一;

归一化:采用最大-最小归一化方法对数据进行归一化:

$$X_{scaled}=\frac{X_i-Min(X_i)}{Max(X_i)-Min(X_i)};$$

其中,X_i 是低空飞行器多变量传感器的原始数据,X_{scaled} 是 X_i 归一化后的数据,$Max(X_i)$和 $Min(X_i)$ 分别表示 X_i 的最大值和最小值;

数据重构:数据在输入到CLKAN多元回归模型之前,重构归一化参数;其数据重构前为:

$$X_{scaled}=\begin{pmatrix} x_{11},x_{12},\ldots,x_{1N} \\ x_{21},x_{22},\ldots,x_{2N} \\ \ldots \\ x_{n1},x_{n2},\ldots,x_{nN} \end{pmatrix},\ x_{ij}\in\mathbb{R}$$

其中 n 是选定具有相关性的低空飞行器传感器的参数数量,N 代表采样点总个数;

对数据应用一个长度为 D 的滑动窗口进行重构:

$$X_{t-D}=\begin{pmatrix} x_{1,t-D+1},x_{1,t-D+2},\ldots,x_{1,t} \\ x_{2,t-D+1},x_{2,t-D+2},\ldots,x_{2,t} \\ \ldots \\ x_{n,t-D+1},x_{n,t-D+2},\ldots,x_{n,t} \end{pmatrix}$$

重构后的多元时间序列数据 $X_{input}=\{X_1,X_2,\ldots,X_{N-D}\}$ 用于模型输入;

所述特征选择,包括:采用MIC相关性分析方法,在数据中选出与监测参数具有强相关

性的参数；

具体包括：给定两个离散的随机变量 $U=\{u_i,i=1,\ldots,n\}$ 和 $V=\{v_i,i=1,\ldots,n\}$，其中 n 是样本数量，互信息 $MI(U,V)$ 为：

$$MI(U,V)=\sum_{u\in U}\sum_{v\in V}p(u,v)\log\frac{p(u,v)}{p(u)p(v)}$$

其中，$p(u,v)$ 表示变量 U 和 V 的联合概率密度，$p(u)$ 和 $p(v)$ 分别是通过直方图估计方法计算的变量 U 和 V 的边际概率密度；

对于一个由有序对构成的有限数据集 $S=\{(u_i,v_i),i=1,\ldots,n\}$，通过构建一个 $x\times y$ 的网格 G，将 (u_i,v_i) 映射到一个二维网格 G 中的单元格；通过集合 S 中的 (u_i,v_i) 落在网格 G 上的概率分布，计算互信息MI，遍历分辨率（$x\times y$）不同的划分网格，并在每种分辨率下改变X轴和Y轴分割点的位置，搜索计算到该分辨率下的最大互信息值MI：

$$MI^*(S,x,y)=\max MI(S\mid G)$$

其中，$MI(S|G)$ 表示 G 在 S 上的MI，MIC是特征矩阵中最大的归一化MI值；

特征矩阵和MIC为：

$$M(S)_{x,y}=\frac{MI^*(S,x,y)}{\log\min\{x,y\}}$$

$$MIC(S)=\max_{xy<D(n)}\left\{M(S)_{x,y}\right\}$$

其中，$xy<D(n)$ 表示 $x\times y$ 大小均要小于 $D(n)$ 且 $w(1)\le D(n)\le O(n^{1-\varepsilon}),0<\varepsilon<1$；

互信息最大化时得到的MIC值。

3.根据权利要求1所述的基于CLKAN-RF框架的低空飞行器传感器异常检测方法，其特征在于，所述S2，包括：

S201、1D CNN依次通过卷积层、ReLU层和池化层捕捉多变量传感器的多元时间序列数据中的局部特征；

S202、LSTM通过多层LSTM捕捉多变量传感器的多元时间序列数据中的长期依赖关系；

S203、KAN通过多层KAN学习多变量传感器的多元时间序列数据的内部结构，并通过样条的局部调整优化已学特征。

4.根据权利要求3所述的基于CLKAN-RF框架的低空飞行器传感器异常检测方法，其特征在于，所述S201，包括：

S20101、将S1中多变量传感器的多元时间序列数据作为输入数据，输入1D CNN，卷积层通过使用卷积核捕捉输入数据中的局部特征，表示为：

$$x_j^h=f\left(\sum_{i\in F_j}x_i^{h-1}\circ k_{ij}^h+b_j^h\right)$$

其中x_j^h是第h层输入特征F_j的第j个元素，x是输入数据，k_{ij}^h是卷积核，b_j^h是偏差项，$f(\circ)$表示非线性激活函数；

S20102、池化层从卷积层的输出中提取局部特征：

$$x_j^{h+1} = pooling\left(x_j^h\right)$$

其中x_j^{h+1}是第$h+1$层输入特征F_j的第j个元素，$pooling(\circ)$表示池化操作。

5.根据权利要求4所述的基于CLKAN-RF框架的低空飞行器传感器异常检测方法，其特征在于，所述S202，包括：

经过1D CNN处理后的局部特征输入到LSTM中，捕获时间序列中的长期依赖关系，输出特征向量；

其中LSTM，包括：遗忘门f_t、输入门i_t和输出门o_t，废弃信息由遗忘门f_t控制，如下所示：

$$f_t = \sigma(w_f \bullet [h_{t-1}, x_t] + b_f)$$

其中，h_{t-1}被认为上一时刻的隐藏状态，x_t是当前输入数据，σ是sigmoid激活函数，输出值f_t越接近1，表示保留的信息越多；w_f和b_f是权重矩阵和偏差项；

输入门i_t用于确定更新信息：

$$i_t = \sigma(w_i \bullet [h_{t-1}, x_t] + \mathrm{b_i})$$

$$\tilde{c}_t = \tanh(w_c \bullet [h_{t-1}, x_t] + b_c)$$

$$c_t = f_t * c_{t-1} + i_t * \tilde{c}_t$$

输入门i_t结合遗忘门f_t，计算新的记忆单元c_t，输入门i_t的权重矩阵和偏移项分别用w_i、b_i表示；w_c表示状态权重矩阵，$\tilde{c}_t$表示长期状态；

LSTM单元输出h_t是基于单元的更新状态来实现的，其操作如下：

$$o_t = \sigma(w_o \bullet [h_{t-1}, x_t] + \mathrm{b}_o)$$

$$h_t = o_t * \tanh(c_t)$$

其中，w_o和b_o分别是输出门的权重矩阵和偏移项。

6.根据权利要求5所述的基于CLKAN-RF框架的低空飞行器传感器异常检测方法，其特征在于，所述S203，包括：

LSTM输出的特征向量作为L层KAN网络的输入，KAN网络的预测结果如下：

$$Y = (\Phi_L \circ \Phi_{L-1} \circ \ldots \circ \Phi_2 \circ \Phi_1) X$$

其中每层$\Phi_l, l \in [1,2,\ldots,L]$代表一个KAN层，每个KAN层的输出维度表示为$[n_0, n_1, \ldots, n_L]$

；$(l+1,j)$神经元的单个KAN激活值是所有传入后激活值的总和；

第$(l+1)$层中个 j特征的变换过程为：

$$X_{l+1,j}=\sum_{i=1}^{n_l}\phi_{l,j,i}\left(X_{l,i}\right),\quad j=1,\cdots,n_{l+1}$$

其中 l为层、j为第$(l+1)$层神经元，其矩阵形式定义为：

$$X_{l+1}=\underbrace{\begin{pmatrix}\phi_{l,1,1}(\cdot) & \phi_{l,1,2}(\cdot) & \cdots & \phi_{l,1,n_l}(\cdot)\\ \phi_{l,2,1}(\cdot) & \phi_{l,2,2}(\cdot) & \cdots & \phi_{l,2,n_l}(\cdot)\\ \vdots & \vdots & & \vdots\\ \phi_{l,n_{l+1},1}(\cdot) & \phi_{l,n_{l+1},2}(\cdot) & \cdots & \phi_{l,n_{l+1},n_l}(\cdot)\end{pmatrix}}_{\Phi_l}X_l$$

其中 Φ_l是第 j层KAN所对应的函数矩阵，激活函数 $\phi(x)$是基函数$b(x)$和样条函数的总和：

$$\phi(x)=w_b\ b(x)+w_s\ \mathrm{spline}(x)$$

其中 $b(x)=silu(x)=x/(1+e^{-x})$，spline(g)是B样条函数 $\mathrm{Spline}(x)=\sum_i c_iB_i(x)$ 的线性组合，c_i是可训练的参数。

7.根据权利要求1所述的基于CLKAN-RF框架的低空飞行器传感器异常检测方法，其特征在于，所述多元回归模型的目标函数为：

$$\min J=\frac{1}{l}\sum_{i=1}^{l}\left(\widehat{Y}_i-Y_i\right)^2$$

其中，l是样本长度，$\hat{Y}_i$和 Y_i分别是第 i个样本的预测值和真实值。

8.根据权利要求1所述的基于CLKAN-RF框架的低空飞行器传感器异常检测方法，其特征在于，所述计算训练残差和测试残差为：

$$R_{train}=\left|\widehat{Y}(t)_{train}-Y(t)_{train}\right|$$

$$R_{test}=\left|\widehat{Y}(t)_{test}-Y(t)_{test}\right|$$

其中，$\hat{Y}(t)_{train}$、$Y(t)_{train}$和 R_{train}分别是训练集的预测值、真实值和残差；$\hat{Y}(t)_{test}$、$Y(t)_{test}$和 R_{test}分别是测试集的预测值、真实值和残差。

9.根据权利要求1所述的基于CLKAN-RF框架的低空飞行器传感器异常检测方法，其特征在于，所述双向自适应指数加权移动平均法平滑残差序列为：

$$\begin{cases} F_1 = R_1 \\ F_t = \dfrac{\rho F_{t-1}}{1-\rho^t} + \dfrac{(1-\rho)R_t}{1-\rho^t}, t \geq 2 \end{cases}$$

$$\begin{cases} S_L = R_L \\ S_t = \dfrac{\rho S_{t+1}}{1-\rho^{L-t+1}} + \dfrac{(1-\rho)R_t}{1-\rho^{L-t+1}}, t \leq L-1 \end{cases}$$

其中 $R=[R_1,R_2,...,R_L]$ 是长度为 L 的训练集的预测残差序列，R_t、F_t 和 S_t 分别是第 t 个时间戳的未平滑残差值、正向和反向平滑残差值，ρ 是初始权重因子，ρ 的初始值与窗口宽度 D 相关，初始值设置如下：

$$\rho = 1/(D+1)$$

选取时间戳 t 处正向平滑残差 F_t 和反向平滑残差 R_t 的最小值作为最终平滑值，表示如下：

$$R_{smooth,t} = \min(F_t, S_t)。$$

10.根据权利要求1所述的基于CLKAN-RF框架的低空飞行器传感器异常检测方法，其特征在于，所述S6，包括：

S601、根据平滑后的残差计算动态阈值，动态阈值能够根据滑动窗口变化，并同时利用训练阶段的信息和测试数据的残差；其中动态阈值利用移动平均线和移动标准差来计算：

$$T_t = \alpha E + \beta S$$

$$E = \mu_{train} + \eta \sigma_{train}$$

$$S = \mu_{test} + \sigma_{test}$$

$$\mu_{test} = \frac{1}{k}\sum_{i=n-k}^{n-1} x_i$$

$$\sigma_{test} = \sigma(x_{n-k}, x_{n-k+1}, ..., x_{n-1})$$

其中 α、β 和 η 是对 E 和 S 进行加权的常数，E 由训练数据的残差序列的均值和标准差组成，S 由测试数据的残差序列的均值和标准差组成滑动窗口内的数据，T_t 即为 t 个时间戳时的动态阈值；

S602、比较测试残差和动态阈值，进行传感器异常检测，若 $R_{smooth,t} \geq T_t$，则判定为异常样本点；若 $R_{smooth,t} < T_t$，则判定为正常样本点；

S603、根据传感器异常检测，输出检测性能指标；其中检测性能指标，包括：TPR、FPR和ACC一种或多种；

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

$$ACC = \frac{TP + TN}{TP + FP + TN + FN}$$

其中，TP 和 TN 分别代表正确识别的正常样本点和异常样本点的数量，而 FP 和 FN 则分别代表错误分类的正常样本点和异常样本点的数量。

一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法

技术领域

[0001] 本发明涉及低空飞行器传感器异常检测技术领域,具体为一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法。

背景技术

[0002] 低空经济产业是指利用低空空域(通常指距地面1000米以下的高度范围)进行的各种商业活动和服务的集合。随着航空技术的发展和相关政策法规的完善,低空经济正在成为新的经济增长点,涵盖了多个领域,并展现出巨大的发展潜力,其中各类低空飞行器是实现低空经济高质量发展的核心载体。

[0003] 在低空飞行中,准确及时地感知外部环境和内部状态对低空飞行器的安全飞行非常重要,很大程度上依赖于各种机载传感器。然而,这些传感器作为精密仪器,对运行环境高度敏感,经常面临极端温度、高湿度和电磁干扰等恶劣条件,很容易出现异常或故障,导致测量信号出现偏差,严重影响指令计算和行动操作,有可能造成坠机事故。因此,开发有效的传感器异常检测方法对于提高低空飞行器可靠性、安全性和飞行效率至关重要。

[0004] 现有的低空飞行器传感器异常检测技术主要分为基于模型的方法和数据驱动的方法前者需要精确的物理模型,而数据驱动方法无需精确的动态建模,目前已成为主流方法。

[0005] 但是数据驱动的异常检测方法仍面临一些挑战:首先,获取带标签的真实传感器异常数据困难且成本高昂;其次,低空飞行器传感器数据本身具有高维性,直接利用此类数据往往会加剧过拟合风险和计算复杂性;此外,大多数研究强调数据中的时间相关性,却忽略了空间模式,限制了捕捉复杂特征的能力,降低了检测性能;最后,真实低空飞行器传感器数据中的随机噪声和干扰会增加漏检率和误检率,尤其是在使用静态阈值时,现有异常检测模型准确性低及鲁棒性差。

发明内容

[0006] 本发明意在提供一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法,用于执行低空飞行器传感器异常检测任务,能解决带标签的真实传感器异常数据稀缺难以获取、依赖专家经验和不相关变量对模型训练的负面影响、以及现有异常检测模型准确性低及鲁棒性差的问题。

[0007] 本发明提供如下基础方案:一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法,包括如下内容:

S1、获取低空飞行器正常飞行状态下的多变量传感器的数据,对多变量传感器数据进行预处理和特征选择,并划分为训练集和测试集;

S2、采用1D CNN、LSTM和KAN,构建 CLKAN多元回归模型;

S3、采用训练集训练CLKAN多元回归模型,并根据预设的目标函数,获取最优的CLKAN多元回归模型;

S4、采用包含异常样本的测试集测试CLKAN多元回归模型,并根据预测值和实际值计算训练残差和测试残差;

S5、采用双向自适应指数加权移动平均法平滑残差序列;

S6、根据平滑后的残差计算动态阈值,并通过比较测试残差和动态阈值,进行传感器异常检测。

[0008] 进一步,所述预处理,包括:数据清洗、归一化和数据重构;

数据清洗:采用线性插值法填充缺失的数据、删除飞行初始阶段不稳定的数据和采用重采样的方法将低空飞行器多变量传感器的数据在时间轴上进行统一;

归一化:采用最大-最小归一化方法对数据进行归一化:

$$X_{scaled}=\frac{X_i-Min(X_i)}{Max(X_i)-Min(X_i)};$$

其中,X_i是低空飞行器多变量传感器的原始数据,X_{scaled}是X_i归一化后的数据,$Max(X_i)$和$Min(X_i)$分别表示X_i的最大值和最小值;

数据重构:数据在输入到CLKAN多元回归模型之前,重构归一化参数;其数据重构前为:

$$X_{scaled}=\begin{pmatrix} x_{11},x_{12},\ldots,x_{1N} \\ x_{21},x_{22},\ldots,x_{2N} \\ \ldots \\ x_{n1},x_{n2},\ldots,x_{nN} \end{pmatrix},\ x_{ij}\in\mathbb{R}$$

[0009] 其中n是选定具有相关性的低空飞行器传感器的参数数量,N代表采样点总个数;

对数据应用一个长度为D的滑动窗口进行重构:

$$X_{t-D}=\begin{pmatrix} x_{1,t-D+1},x_{1,t-D+2},\ldots,x_{1,t} \\ x_{2,t-D+1},x_{2,t-D+2},\ldots,x_{2,t} \\ \ldots \\ x_{n,t-D+1},x_{n,t-D+2},\ldots,x_{n,t} \end{pmatrix}$$

[0010] 重构后的多元时间序列数据$X_{input}=\{X_1,X_2,\ldots,X_{N-D}\}$用于模型输入;

所述特征选择,包括:采用MIC相关性分析方法,在数据中选出与监测参数具有强相关性的参数;

具体包括:给定两个离散的随机变量$U=\{u_i,i=1,\ldots,n\}$和$V=\{v_i,i=1,\ldots,n\}$,其中n是样本数量,互信息$MI(U,V)$为:

$$MI(U,V)=\sum_{u\in U}\sum_{v\in V}p(u,v)\log\frac{p(u,v)}{p(u)p(v)}$$

[0011] 其中，$p(u,v)$表示变量 U 和 V 的联合概率密度，$p(u)$和 $p(v)$分别是通过直方图估计方法计算的变量 U 和 V 的边际概率密度；

对于一个由有序对构成的有限数据集 $S=\{(u_i,v_i),i=1,\ldots,n\}$，通过构建一个 $x\times y$ 的网格 G，将(u_i,v_i)映射到一个二维网格 G 中的单元格；通过集合 S 中的(u_i,v_i)落在网格 G 上的概率分布，计算互信息MI，遍历分辨率（$x\times y$）不同的划分网格，并在每种分辨率下改变X轴和Y轴分割点的位置，搜索计算到该分辨率下的最大互信息值MI：

$$MI^*(S,x,y)=\max MI(S|G)$$

[0012] 其中，$MI(S|G)$ 表示 G 在 S 上的MI，MIC是特征矩阵中最大的归一化MI值；

特征矩阵和MIC为：

$$M(S)_{x,y}=\frac{MI^*(S,x,y)}{\log\min\{x,y\}}$$

[0013] $$MIC(S)=\max_{xy<D(n)}\{M(S)_{x,y}\}$$

[0014] 其中，$xy<D(n)$表示$x\times y$ 大小均要小于 $D(n)$且

$w(1)\le D(n)\le O(n^{1-\varepsilon}),0<\varepsilon<1$；

互信息最大化时得到的MIC值。

[0015] 进一步，所述S2，包括：

S201、1D CNN依次通过卷积层、ReLU层和池化层捕捉多变量传感器的多元时间序列数据中的局部特征；

S202、LSTM通过多层LSTM捕捉多变量传感器的多元时间序列数据中的长期依赖关系；

S203、KAN通过多层KAN学习多变量传感器的多元时间序列数据的内部结构，并通过样条的局部调整优化已学特征。

[0016] 进一步，所述S201，包括：

S20101、将S1中多变量传感器的多元时间序列数据作为输入数据，输入1D CNN，卷积层通过使用卷积核捕捉输入数据中的局部特征，表示为：

$$x_j^h=f\left(\sum_{i\in F_j}x_i^{h-1}\circ k_{ij}^h+b_j^h\right)$$

[0017] 其中x_j^h是第 h层输入特征 F_j的第 j个元素，x 是输入数据，k_{ij}^h是卷积核，b_j^h是偏差项，$f(\circ)$表示非线性激活函数；

S20102、池化层从卷积层的输出中提取局部特征：

$$x_j^{h+1} = pooling\left(x_j^h\right)$$

[0018] 其中x_j^{h+1}是第$h+1$层输入特征F_j的第j个元素，$pooling(\circ)$表示池化操作。

[0019] 进一步，所述S202，包括：

经过1D CNN处理后的局部特征输入到LSTM中，捕获时间序列中的长期依赖关系，输出特征向量；

其中LSTM，包括：遗忘门f_t、输入门i_t和输出门o_t，废弃信息由遗忘门f_t控制，如下所示：

$$f_t = \sigma(w_f g[h_{t-1}, x_t] + b_f)$$

[0020] 其中，h_{t-1}被认为上一时刻的隐藏状态，x_t是当前输入数据，σ是sigmoid激活函数，输出值f_t越接近1，表示保留的信息越多；w_f和b_f是权重矩阵和偏差项；

输入门i_t用于确定更新信息：

$$i_t = \sigma(w_i \bullet [h_{t-1}, x_t] + \mathrm{b}_i)$$

[0021] $$\tilde{c}_t = \tanh(w_c \bullet [h_{t-1}, x_t] + b_c)$$

[0022] $$c_t = f_t * c_{t-1} + i_t * \tilde{c}_t$$

[0023] 输入门i_t结合遗忘门f_t，计算新的记忆单元c_t，输入门i_t的权重矩阵和偏移项分别用w_i、b_i表示；w_c表示状态权重矩阵，$\tilde{c}_t$表示长期状态；

LSTM单元输出h_t是基于单元的更新状态来实现的，其操作如下：

$$o_t = \sigma(w_o g[h_{t-1}, x_t] + \mathrm{b}_o)$$

[0024] $$h_t = o_t * \tanh(c_t)$$

[0025] 其中，w_o和b_o分别是输出门的权重矩阵和偏移项。

[0026] 进一步，所述S203，包括：

LSTM输出的特征向量作为L层KAN网络的输入，KAN网络的预测结果如下：

$$Y = (\Phi_L \circ \Phi_{L-1} \circ \ldots \circ \Phi_2 \circ \Phi_1) X$$

[0027] 其中每层$\Phi_l, l \in [1,2,\ldots,L]$代表一个KAN层，每个KAN层的输出维度表示为$[n_0, n_1, \ldots, n_L]$；$(l+1, j)$神经元的单个KAN激活值是所有传入后激活值的总和；

第$(l+1)$层中个j特征的变换过程为：

$$X_{l+1,j} = \sum_{i=1}^{n_l} \phi_{l,j,i}(X_{l,i}), \quad j = 1, \mathrm{L}, n_{l+1}$$

[0028] 其中 l 为层、j 为第 $(l+1)$ 层神经元，其矩阵形式定义为：

$$X_{l+1}=\underbrace{\begin{pmatrix}\phi_{l,1,1}(\cdot) & \phi_{l,1,2}(\cdot) & \cdots & \phi_{l,1,n_l}(\cdot)\\ \phi_{l,2,1}(\cdot) & \phi_{l,2,2}(\cdot) & \cdots & \phi_{l,2,n_l}(\cdot)\\ \vdots & \vdots & & \vdots\\ \phi_{l,n_{l+1},1}(\cdot) & \phi_{l,n_{l+1},2}(\cdot) & \cdots & \phi_{l,n_{l+1},n_l}(\cdot)\end{pmatrix}}_{\Phi_l}X_l$$

[0029] 其中 Φ_l 是第 j 层KAN所对应的函数矩阵，激活函数 $\phi(x)$ 是基函数 $b(x)$ 和样条函数的总和：

$$\phi(x)=w_b\ b(x)+w_s\ \mathrm{spline}(x)$$

[0030] 其中 $b(x)=silu(x)=x/(1+e^{-x})$，spline(g)是B样条函数 $\mathrm{Spline}(x)=\sum_i c_i B_i(x)$ 的线性组合，c_i 是可训练的参数。

[0031] 进一步，所述多元回归模型的目标函数为：

$$\min J=\frac{1}{l}\sum_{i=1}^{l}\left(\widehat{Y}_i-Y_i\right)^2$$

[0032] 其中，l 是样本长度，$\hat{Y}_i$ 和 Y_i 分别是第 i 个样本的预测值和真实值。

[0033] 进一步，所述计算训练残差和测试残差为：

$$R_{train}=\left|\widehat{Y}(t)_{train}-Y(t)_{train}\right|$$

[0034] $$R_{test}=\left|\widehat{Y}(t)_{test}-Y(t)_{test}\right|$$

[0035] 其中，$\hat{Y}(t)_{train}$、$Y(t)_{train}$ 和 R_{train} 分别是训练集的预测值、真实值和残差；$\hat{Y}(t)_{test}$、$Y(t)_{test}$ 和 R_{test} 分别是测试集的预测值、真实值和残差。

[0036] 进一步，所述双向自适应指数加权移动平均法平滑残差序列为：

$$\begin{cases}F_1=R_1\\ F_t=\dfrac{\rho F_{t-1}}{1-\rho^t}+\dfrac{(1-\rho)R_t}{1-\rho^t},t\geq 2\end{cases}$$

[0037] $$\begin{cases}S_L=R_L\\ S_t=\dfrac{\rho S_{t+1}}{1-\rho^{L-t+1}}+\dfrac{(1-\rho)R_t}{1-\rho^{L-t+1}},t\leq L-1\end{cases}$$

[0038] 其中 $R=[R_1,R_2,\ldots,R_L]$ 是长度为 L 的训练集的预测残差序列，R_t、F_t 和 S_t 分别是第 t 个时间戳的未平滑残差值、正向和反向平滑残差值，ρ 是初始权重因子，ρ 的初始

值与窗口宽度 D 相关,初始值设置如下:

$$\rho = 1/(D+1)$$

[0039] 选取时间戳 t 处正向平滑残差 F_t 和反向平滑残差 R_t 的最小值作为最终平滑值,表示如下:

$$R_{smooth,t} = \min(F_t, S_t)。$$

[0040] 进一步,所述S6,包括:

S601、根据平滑后的残差计算动态阈值,动态阈值能够根据滑动窗口变化,并同时利用训练阶段的信息和测试数据的残差;其中动态阈值利用移动平均线和移动标准差来计算:

$$T_t = \alpha E + \beta S$$

[0041] $$E = \mu_{train} + \eta \sigma_{train}$$

[0042] $$S = \mu_{test} + \sigma_{test}$$

[0043] $$\mu_{test} = \frac{1}{k}\sum_{i=n-k}^{n-1} x_i$$

[0044] $$\sigma_{test} = \sigma(x_{n-k}, x_{n-k+1}, \ldots, x_{n-1})$$

[0045] 其中 α、β 和 η 是对 E 和 S 进行加权的常数,E 由训练数据的残差序列的均值和标准差组成,S 由测试数据的残差序列的均值和标准差组成滑动窗口内的数据,T_t 即为第 t 个时间戳时的动态阈值;

S602、比较测试残差和动态阈值,进行传感器异常检测,若 $R_{smooth,t} \geq T_t$,则判定为异常样本点;若 $R_{smooth,t} < T_t$,则判定为正常样本点;

S603、根据传感器异常检测,输出检测性能指标;其中检测性能指标,包括:TPR、FPR和ACC;

$$TPR = \frac{TP}{TP+FN}$$

[0046] $$FPR = \frac{FP}{FP+TN}$$

[0047] $$ACC = \frac{TP+TN}{TP+FP+TN+FN}$$

[0048] 其中,TP 和 TN 分别代表正确识别的正常样本点和异常样本点的数量,而 FP 和 FN 则分别代表错误分类的正常样本点和异常样本点的数量。

[0049] 本方案的有益效果:本方案中CLKAN-RF异常检测框架不依赖大量带标签异常数据,只使用易获取的低空飞行器正常飞行状态下的多变量传感器数据;首先,对原始数据进行重采样、归一化等一系列处理,并利用MIC相关性分析方法选择传感器参数;然后,通过所

设计的CLKAN回归模型全面捕捉了低空飞行器传感器数据中复杂的时空特征和相互依存关系,基于最小损失保存最佳模型;再然后,将含异常样本的测试集输入经过训练的模型,并根据预测值和实际值计算训练残差和测试残差,另外,对残差序列使用双向自适应指数加权移动平均法平滑处理;最后,根据平滑后的残差计算动态阈值,并通过比较测试残差和动态阈值实现传感器高精度异常检测。

[0050] 本方案能够实现低空飞行器传感器多种异常检测,在数据方面,由于获取大量带标签的真实传感器异常数据困难且成本高昂,故在训练期间,只使用易获取的低空飞行器正常飞行状态下的多变量传感器数据,并通过数据注入仿真生成各种传感器异常样本用于检测方法性能;在回归预测方面,充分利用低空飞行器传感器数据中时间、空间关联关系,相比当前其他先进回归算法,拥有更优越的预测性能;在预测残差检测方面,不采用固定的统计检测阈值对预测残差直接进行判读,而是对残差序列使用双向自适应指数加权移动平均法平滑后计算自适应的动态阈值,克服随机噪声和静态阈值对检测性能的不利影响。

[0051] 具体地,1、本方案中不依赖大量标签异常数据,只使用低空飞行器正常飞行状态下的多变量传感器的数据,显著降低低空飞行器传感器异常检测的成本;

2、使用MIC相关性分析方法选择传感器参数,以避免不相关变量对模型训练的负面影响,同时降低计算复杂性和对专家知识的依赖;

3、结合一维CNN在局部特征、LSTM在时间特征提取和KAN在非线性数据表征方面的优势,全面捕捉了低空飞行器传感器数据中复杂的时空特征和相互依存关系,显著增强了模型的特征提取能力和鲁棒性;

4、通过双向自适应指数加权移动平均法来平滑残差序列,消除随机噪声和数据波动对模型性能的不利影响,能够显著降低误报率;

5、采用一种自适应动态阈值机制,克服了传统静态阈值的局限性,进一步降低漏报和误报,有效提升检测的精确度。

[0052] 综上所述,本方案用于执行低空飞行器传感器异常检测任务,能解决带标签的真实传感器异常数据稀缺难以获取、依赖专家经验和不相关变量对模型训练的负面影响、以及现有异常检测模型准确性低及鲁棒性差的问题。

附图说明

[0053] 图1为本发明一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法实施例的流程示意图;

图2为本发明一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法实施例的原理框图;

图3为本发明一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法实施例的模型网络结构参图;

图4为本发明一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法实施例中模型在数据集上的回归性能对比图;

图5为本发明一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法实施例中模型在低空飞行器传感器异常任务上的性能指标对比图;

图6为本发明一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法实施例中

模型不同阈值策略对比图。

具体实施方式

[0054] 下面通过具体实施方式进一步详细说明：

实施例基本如附图1所示：一种基于CLKAN-RF框架的低空飞行器传感器异常检测方法，包括如下内容：

S1、获取低空飞行器正常飞行状态下的多变量传感器的数据，对多变量传感器数据进行预处理和特征选择，并划分为训练集和测试集；

其中预处理，包括：数据清洗、归一化和数据重构；

具体地，数据清洗：采用线性插值法填充缺失的数据、删除飞行初始阶段不稳定的数据和采用重采样的方法将低空飞行器多变量传感器的数据在时间轴上进行统一，采样频率为25Hz。

[0055] 归一化：采用最大-最小归一化方法对数据进行归一化，其定义如下：

$$X_{scaled}=\frac{X_i-Min(X_i)}{Max(X_i)-Min(X_i)};$$

其中，X_i是低空飞行器多变量传感器的原始数据，X_{scaled}是X_i归一化后的数据，$Max(X_i)$和$Min(X_i)$分别表示X_i的最大值和最小值。

[0056] 数据重构：数据在输入到CLKAN多元回归模型之前，需要重构归一化参数以匹配模型的输入格式和更好地捕获时间相关性，其数据重构前可以表示为：

$$X_{scaled}=\begin{pmatrix} x_{11},x_{12},\ldots,x_{1N} \\ x_{21},x_{22},\ldots,x_{2N} \\ \ldots \\ x_{n1},x_{n2},\ldots,x_{nN} \end{pmatrix},\ x_{ij}\in\mathbb{R}$$

[0057] 其中n是选定具有相关性的低空飞行器传感器的参数数量，N代表采样点总个数；

对数据应用一个长度为D的滑动窗口进行重构，其定义如下：

$$X_{t-D}=\begin{pmatrix} x_{1,t-D+1},x_{1,t-D+2},\ldots,x_{1,t} \\ x_{2,t-D+1},x_{2,t-D+2},\ldots,x_{2,t} \\ \ldots \\ x_{n,t-D+1},x_{n,t-D+2},\ldots,x_{n,t} \end{pmatrix}$$

[0058] 重构后的多元时间序列数据$X_{input}=\{X_1,X_2,\ldots,X_{N-D}\}$用于模型输入。

[0059] 特征选择，包括：采用最大信息系数(MIC)相关性分析方法，在数据中选出与监测参数具有强相关性的参数；其中监测参数为IMU传感器的参数滚转角(roll angle)；

具体地，MIC的原理为通过在散点图上尝试不同的网格划分，计算变量间的互信息

(MI),以寻找最能揭示它们相关性的划分;

给定两个离散的随机变量 $U=\{u_i,i=1,\ldots,n\}$ 和 $V=\{v_i,i=1,\ldots,n\}$,其中 n 是样本数量,互信息 $MI(U,V)$ 定义为:

$$MI(U,V)=\sum_{u\in U}\sum_{v\in V}p(u,v)\log\frac{p(u,v)}{p(u)p(v)}$$

[0060] 其中,$p(u,v)$ 表示变量 U 和 V 的联合概率密度,$p(u)$ 和 $p(v)$ 分别是通过直方图估计方法计算的变量 U 和 V 的边际概率密度;

对于一个由有序对构成的有限数据集 $S=\{(u_i,v_i),i=1,\ldots,n\}$,通过构建一个 $x\times y$ 的网格 G,将 (u_i,v_i) 映射到一个二维网格 G 中的单元格;通过集合 S 中的 (u_i,v_i) 落在网格 G 上的概率分布,计算互信息MI,遍历分辨率($x\times y$)不同的划分网格,并在每种分辨率下改变X轴和Y轴分割点的位置,搜索计算到该分辨率下的最大互信息值MI:

$$MI^*(S,x,y)=\max MI(S\mid G)$$

[0061] 其中,$MI(S|G)$ 表示 G 在 S 上的MI,MIC是特征矩阵中最大的归一化MI值;

特征矩阵和MIC定义如下:

$$M(S)_{x,y}=\frac{MI^*(S,x,y)}{\log\min\{x,y\}}$$

[0062] $$MIC(S)=\max_{xy<D(n)}\left\{M(S)_{x,y}\right\}$$

[0063] 其中,$xy<D(n)$ 表示 $x\times y$ 大小均要小于 $D(n)$ 且 $w(1)\le D(n)\le O(n^{1-\varepsilon}),0<\varepsilon<1$;

互信息最大化时得到的MIC值,范围0到1,反映了变量间相关性的强度。一般来说,$D(n)$ 设置为 $n^{0.6}$,就可以表示变量 U 和 V 强相关,因此本实施例中 $D(n)$ 设置为 $n^{0.6}$,表示变量 U 和 V 强相关。

[0064] 其中训练集和测试集的数据划分占比为80%和20%,数据集之间相互独立。

[0065] S2、采用一维卷积神经网络(one-dimensional convolutional neural network ,1D CNN)、长短期记忆网络(long short-term memory network ,LSTM)和科尔莫戈洛夫-阿诺德网络(Kolmogorov-Arnold network ,KAN)),构建 CLKAN多元回归模型;

CLKAN多元回归模型由1D CNN、LSTM和KAN三个组件依次有效组合,能够全面地捕捉传感器数据中复杂时空特征和相互依赖性,具体构建过程如下:

S201、1D CNN依次通过卷积层、ReLU层和池化层捕捉多变量传感器的多元时间序列数据中的局部特征;

具体地,S20101、将S1中多变量传感器的多元时间序列数据作为输入数据,输入1D

CNN,卷积层通过使用卷积核捕捉输入数据中的局部特征,表示为:

$$x_j^h = f\left(\sum_{i \in F_j} x_i^{h-1} \circ k_{ij}^h + b_j^h\right)$$

[0066] 其中x_j^h是第h层输入特征F_j的第j个元素,x是输入数据,k_{ij}^h是卷积核,b_j^h是偏差项,$f(\circ)$表示非线性激活函数;

其中非线性激活函数,采用ReLU激活函数,通过ReLU激活函数引入非线性,使模型能够捕捉更复杂的特征和模式,同时提高计算效率和模型性能,这种激活有助于缓解梯度消失问题并加速训练期间模型的收敛,其定义如下:

$$\mathrm{Re}LU(x) = \max(0, x)$$ 。

[0067] S20102、池化层从卷积层的输出中提取局部特征;采用池化层从输入数据中提取最显著的特征来降低数据的维度,同时保持重要的信息,其定义如下:

$$x_j^{h+1} = pooling(x_j^h)$$

[0068] 其中x_j^{h+1}是第$h+1$层输入特征F_j的第j个元素,$pooling(\circ)$表示池化操作。

[0069] S202、LSTM通过多层LSTM捕捉多变量传感器的多元时间序列数据中的长期依赖关系;

具体地,经过1D CNN处理后的局部特征输入到LSTM中,LSTM是一种特殊的循环神经网络(RNN)架构,以其独特的门控机制著称,能够调节信息流,从而捕获时间序列中的长期依赖关系,输出特征向量;

LSTM,包括:遗忘门f_t、输入门i_t和输出门o_t,废弃信息由遗忘门f_t控制,如下所示:

$$f_t = \sigma(w_f \bullet [h_{t-1}, x_t] + b_f)$$

[0070] 其中,h_{t-1}被认为上一时刻的隐藏状态,x_t是当前输入数据,σ是sigmoid激活函数,输出值f_t越接近1,表示保留的信息越多;w_f和b_f是权重矩阵和偏差项;

输入门i_t用于确定更新信息,表示如下:

$$i_t = \sigma(w_i \bullet [h_{t-1}, x_t] + \mathrm{b_i})$$

[0071] $$\tilde{c}_t = \tanh(w_c \bullet [h_{t-1}, x_t] + b_c)$$

[0072] $$c_t = f_t * c_{t-1} + i_t * \tilde{c}_t$$

[0073] 输入门i_t结合遗忘门f_t,计算新的记忆单元c_t,输入门i_t的权重矩阵和偏移项分别用w_i、b_i表示;w_c表示状态权重矩阵,$\overset{\circ}{c}_t$表示长期状态;

LSTM单元输出 h_t 是基于单元的更新状态来实现的,其操作如下:

$$o_t = \sigma(w_o \bullet [h_{t-1}, x_t] + \mathrm{b}_o)$$

[0074] $$h_t = o_t * \tanh(c_t)$$

[0075] 其中,w_o 和 b_o 分别是输出门的权重矩阵和偏移项。

[0076] S203、KAN通过多层KAN学习多变量传感器的多元时间序列数据的内部结构,并通过样条的局部调整优化已学特征。

[0077] 具体地LSTM的输出通过KAN映射到所需的输出维度,KAN这种新颖的架构结合了B样条和MLP,B样条擅长通过精确的局部控制来逼近低维函数,而MLP则擅长构建具有强大特征学习能力的复杂模型,KAN网络将这两者结合起来,增强了多变量时间序列数据的学习和优化能力;

LSTM输出的特征向量作为L层KAN网络的输入,KAN网络的预测结果如下:

$$Y = (\Phi_L \circ \Phi_{L-1} \circ \ldots \circ \Phi_2 \circ \Phi_1) X$$

[0078] 其中每层 $\Phi_l, l \in [1,2,\ldots,L]$ 代表一个KAN层,每个KAN层的输出维度表示为 $[n_0, n_1, \ldots, n_L]$;$(l+1, j)$ 神经元的单个KAN激活值是所有传入后激活值的总和;

因此,第 $(l+1)$ 层中个 j 特征的变换过程表示为:

$$X_{l+1,j} = \sum_{i=1}^{n_l} \phi_{l,j,i}(X_{l,i}), \quad j = 1, \mathrm{L}, n_{l+1}$$

[0079] 其中 l 为层、j 为第 $(l+1)$ 层神经元,其矩阵形式定义为:

$$X_{l+1} = \underbrace{\begin{pmatrix} \phi_{l,1,1}(\cdot) & \phi_{l,1,2}(\cdot) & \cdots & \phi_{l,1,n_l}(\cdot) \\ \phi_{l,2,1}(\cdot) & \phi_{l,2,2}(\cdot) & \cdots & \phi_{l,2,n_l}(\cdot) \\ \vdots & \vdots & & \vdots \\ \phi_{l,n_{l+1},1}(\cdot) & \phi_{l,n_{l+1},2}(\cdot) & \cdots & \phi_{l,n_{l+1},n_l}(\cdot) \end{pmatrix}}_{\Phi_l} X_l$$

[0080] 其中 Φ_l 是第 j 层KAN所对应的函数矩阵,激活函数 $\phi(x)$ 是基函数 $b(x)$ 和样条函数的总和:

$$\phi(x) = w_b\ b(x) + w_s\ \mathrm{spline}(x)$$

[0081] 其中 $b(x) = silu(x) = x/(1+e^{-x})$,spline(g)是B样条函数 $\mathrm{Spline}(x) = \sum_i c_i B_i(x)$ 的线性组合,c_i 是可训练的参数。

[0082] S3、采用训练集训练CLKAN多元回归模型,并根据预设的目标函数,获取最优的CLKAN多元回归模型;

其中多元回归模型的目标函数为：

$$\min J=\frac{1}{l}\sum_{i=1}^{l}\left(\widehat{Y}_i-Y_i\right)^2$$

[0083] 其中，l是样本长度，$\hat{Y}_i$和Y_i分别是第i个样本的预测值和真实值。

[0084] S4、采用包含异常样本的测试集测试CLKAN多元回归模型，并根据预测值和实际值计算训练残差和测试残差；

具体地，计算训练残差和测试残差：

$$R_{train}=\left|\widehat{Y}(t)_{train}-Y(t)_{train}\right|$$

[0085] $$R_{test}=\left|\widehat{Y}(t)_{test}-Y(t)_{test}\right|$$

[0086] 其中，$\widehat{Y}(t)_{train}$、$Y(t)_{train}$和R_{train}分别是训练集的预测值、真实值和残差；$\widehat{Y}(t)_{test}$、$Y(t)_{test}$和R_{test}分别是测试集的预测值、真实值和残差。

[0087] S5、采用双向自适应指数加权移动平均法平滑残差序列；

具体地，双向自适应指数加权移动平均法平滑残差序列为：

$$\begin{cases}F_1=R_1\\ F_t=\dfrac{\rho F_{t-1}}{1-\rho^t}+\dfrac{(1-\rho)R_t}{1-\rho^t},t\geq 2\end{cases}$$

[0088] $$\begin{cases}S_L=R_L\\ S_t=\dfrac{\rho S_{t+1}}{1-\rho^{L-t+1}}+\dfrac{(1-\rho)R_t}{1-\rho^{L-t+1}},t\leq L-1\end{cases}$$

[0089] 其中$R=\left[R_1,R_2,\ldots,R_L\right]$是长度为$L$的训练集的预测残差序列，$R_t$、$F_t$和$S_t$分别是第$t$个时间戳的未平滑残差值、正向和反向平滑残差值，$\rho$是初始权重因子，$\rho$的初始值与窗口宽度$D$相关，初始值设置如下：

$$\rho=1/\left(D+1\right)$$

[0090] 选取时间戳t处正向平滑残差F_t和反向平滑残差R_t的最小值作为最终平滑值，表示如下：

$$R_{smooth,t}=\min\left(F_t,S_t\right)。$$

[0091] S6、根据平滑后的残差计算动态阈值，并通过比较测试残差和动态阈值，进行传感器异常检测。

[0092] 具体地，

S601、根据平滑后的残差计算动态阈值，动态阈值能够根据滑动窗口变化，并同时利用训练阶段的信息和测试数据的残差；其中动态阈值利用移动平均线和移动标准差来计

算,定义如下:

$$T_t = \alpha E + \beta S$$

[0093] $$E = \mu_{train} + \eta \sigma_{train}$$

[0094] $$S = \mu_{test} + \sigma_{test}$$

[0095] $$\mu_{test} = \frac{1}{k} \sum_{i=n-k}^{n-1} x_i$$

[0096] $$\sigma_{test} = \sigma\left(x_{n-k}, x_{n-k+1}, \ldots, x_{n-1}\right)$$

[0097] 其中 α、β 和 η 是对 E 和 S 进行加权的常数,E 由训练数据的残差序列的均值和标准差组成,S 由测试数据的残差序列的均值和标准差组成滑动窗口内的数据,T_t 即为 t 个时间戳时的动态阈值;

S602、比较测试残差和动态阈值,进行传感器异常检测,即若 $R_{smooth,t} \geq T_t$,则判定为异常样本点;若 $R_{smooth,t} < T_t$,则判定为正常样本点;

S603、根据传感器异常检测,输出检测性能指标;其中检测性能指标,包括:真阳性率(True Positive Rate, TPR)、假阳性率(False Positive Rate, FPR)和检测准确率(Accuracy, ACC);

$$TPR = \frac{TP}{TP + FN}$$

[0098] $$FPR = \frac{FP}{FP + TN}$$

[0099] $$ACC = \frac{TP + TN}{TP + FP + TN + FN}$$

[0100] 其中,TP 和 TN 分别代表正确识别的正常样本点和异常样本点的数量,而 FP 和 FN 则分别代表错误分类的正常样本点和异常样本点的数量。

[0101] 本实施例中,数据采集通过定制版的Carbon Z T-28模型飞机收集的,这款飞机翼展达2米,装备有电动发动机、副翼、襟副翼、升降舵和方向舵等关键飞行控制面。此外,飞机还集成了Holybro PX4 2.4.6自动驾驶仪、皮托管、GPS模块以及Nvidia Jetson TX2机载计算机,以支持高精度的飞行控制和数据处理。将来自该飞机多个机载传感器采集的数据经过图2所示的数据处理和特征选择后,将正常飞行状态下的数据输入到CLKAN多元回归模型训练;CLKAN模型具体结构如图3所示,包括一维卷积层、ReLU激活层、池化层、两层LSTM和两层KAN;随后,基于最小训练损失保存基于时空联合学习的最佳CLKAN多元回归模型。

[0102] 为了评估CLKAN方法的有效性将其与当前先进回归模型LSTM-RF和TCN进行了比较,同时为进一步验证模型各组件的有效性做了针对性的消融实验,对不同的模型采用相同的数据,根据模型的输出计算各模型的均方误差(MSE)、均方根误差(RMSE)、平均绝对误差(MAE)、拟合优度(R^2);实验结果如图4所示,展示了CLKAN多元回归模型的MSE、MAE、RMSE

均为最小，R^2为0.9263，与其他方法相比最为接近1。

[0103] 综合来看，本方案具有最为优秀的回归效果；同时，分别去掉1D CNN、LSTM和KAN后模型预测性能均变差，有力证实了各设计组件的有效性。

[0104] 同时，得到如图5所示各方法在低空飞行器传感器异常任务上性能指标对比图。从图5中可以看出，相比其他方法CLKAN-RF性能指标最优。另外，为了验证CLKAN-RF不同组成部分的有效性，进行了有针对性的消融实验。值得注意的是，去掉RF(残差滤波)后，FPR急剧增大，ACC大幅下降，造成大量异常误检。反过来，这说明这种双向自适应指数加权移动平均法残差滤波能大幅消除随机噪声造成的负面影响。另外，从图6可以看出，三种类型的异常检测中，动态阈值相较于静态阈值均展现出了其优势，说明采用自适应的动态阈值有利于进一步提高异常检测性能。

[0105] 本方案中CLKAN-RF异常检测框架不依赖大量带标签异常数据，只使用易获取的低空飞行器正常飞行状态下的多变量传感器数据。首先，对原始数据进行重采样、归一化等一系列处理，并利用MIC相关性分析方法选择传感器参数；然后，通过所设计的CLKAN回归模型全面捕捉了低空飞行器传感器数据中复杂的时空特征和相互依存关系，基于最小损失保存最佳模型；再然后，将含异常样本的测试集输入经过训练的模型，并根据预测值和实际值计算训练残差和测试残差，另外，对残差序列使用双向自适应指数加权移动平均法平滑处理；最后，根据平滑后的残差计算动态阈值，并通过比较测试残差和动态阈值实现传感器高精度异常检测。

[0106] 本方案能够实现低空飞行器传感器多种异常检测，在数据方面，由于获取大量带标签的真实传感器异常数据困难且成本高昂，故在训练期间，只使用易获取的低空飞行器正常飞行状态下的多变量传感器数据，并通过数据注入仿真生成各种传感器异常样本用于检测方法性能；

在回归预测方面，充分利用低空飞行器传感器数据中时间、空间关联关系，相比当前其他先进回归算法，拥有更优越的预测性能；

在预测残差检测方面，不采用固定的统计检测阈值对预测残差直接进行判读，而是对残差序列使用双向自适应指数加权移动平均法平滑后计算自适应的动态阈值，克服随机噪声和静态阈值对检测性能的不利影响。

[0107] 本方案直接使用易获取的低空飞行器正常飞行状态下的多变量传感器数据显著降低了数据获取的成本；利用MIC相关性分析方法选择传感器参数有效避免对专家知识的依赖和无关参数的负面影响；通过先进的CLKAN回归模型全面捕捉了低空飞行器传感器数据中复杂的时空特征和相互依存关系，显著提高了异常检测方法的准确率和鲁棒性；同时，采用一种双向自适应指数加权移动平均法与动态阈值有效结合的残差检测策略，进一步提高了异常检测方法的性能、适应性和可靠性。

[0108] 以上所述的仅是本发明的实施例，方案中公知的具体结构及特性等常识在此未作过多描述，所属领域普通技术人员知晓申请日或者优先权日之前发明所属技术领域所有的普通技术知识，能够获知该领域中所有的现有技术，并且具有应用该日期之前常规实验手段的能力，所属领域普通技术人员可以在本申请给出的启示下，结合自身能力完善并实施本方案，一些典型的公知结构或者公知方法不应当成为所属领域普通技术人员实施本申请的障碍。应当指出，对于本领域的技术人员来说，在不脱离本发明结构的前提下，还可以作

出若干变形和改进,这些也应该视为本发明的保护范围,这些都不会影响本发明实施的效果和专利的实用性。本申请要求的保护范围应当以其权利要求的内容为准,说明书中的具体实施方式等记载可以用于解释权利要求的内容。

S1、获取低空飞行器正常飞行状态下的多变量传感器的数据，对多变量传感器数据进行预处理和特征选择，并划分为训练集和测试集
S2、采用1D CNN、LSTM和KAN，构建 CLKAN多元回归模型
S3、采用训练集训练CLKAN多元回归模型，并根据预设的目标函数，获取最优的CLKAN多元回归模型
S4、采用包含异常样本的测试集测试CLKAN多元回归模型，并根据预测值和实际值计算训练残差和测试残差
S5、采用双向自适应指数加权移动平均法平滑残差序列
S6、根据平滑后的残差计算动态阈值，并通过比较测试残差和动态阈值，进行传感器异常检测

图1

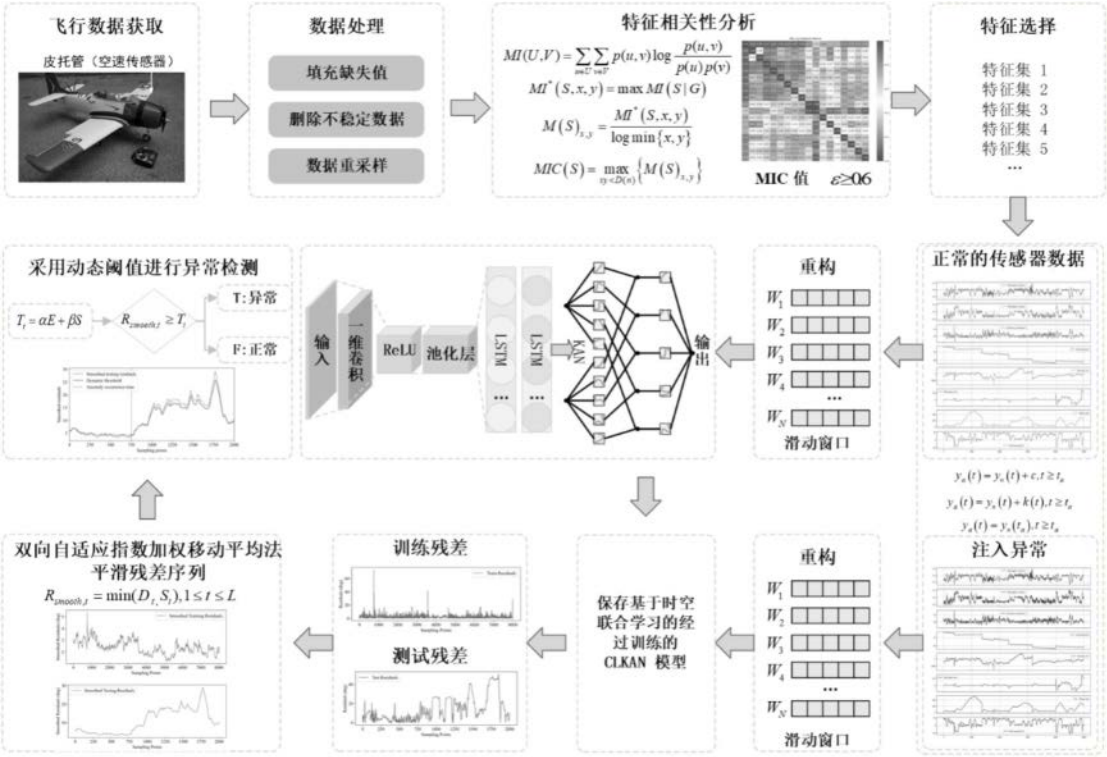
飞行数据获取
皮托管（空速传感器）
数据处理
填充缺失值
删除不稳定数据
数据重采样
特征相关性分析
MIC 值 ε≥0.6
特征选择
特征集 1
特征集 2
特征集 3
特征集 4
特征集 5
…
正常的传感器数据
重构
滑动窗口
注入异常
重构
滑动窗口
保存基于时空联合学习的经过训练的CLKAN 模型
训练残差
测试残差
双向自适应指数加权移动平均法平滑残差序列
采用动态阈值进行异常检测
T:异常
F:正常
输入
一维卷积
ReLU
池化层
LSTM
LSTM
KAN
输出

图2

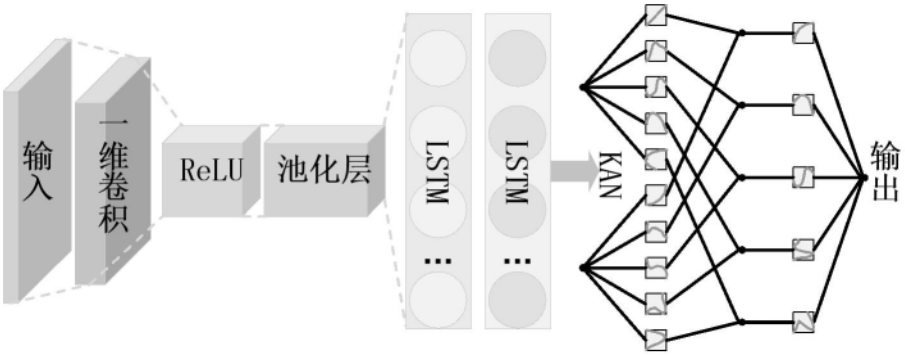
输入
一维卷积
ReLU
池化层
LSTM
LSTM
KAN
输出

图3

模型	MSE	MAE	RMSE	R^2
No LSTM	0.0935	0.2164	0.3044	0.6472
No 1D CNN	0.0498	0.1635	0.2231	0.8121
No KAN	0.0369	0.1421	0.1876	0.8658
TCN	0.0747	0.2027	0.2734	0.7179
TCN-KAN	0.0450	0.1564	0.2121	0.8302
LSTM-RF	0.0710	0.1910	0.2664	0.7320
CLKAN	**0.0194**	**0.1098**	**0.1394**	**0.9263**

图4

异常类型	方法	评估指标		
		TPR	FPR	ACC
偏置异常	No LSTM	59.46	10.68	78.13
	No RF	97.80	66.88	57.38
	No 1D CNN	96.67	11.08	92.90
	No KAN	89.40	1.40	95.15
	TCN-KAN-RF	93.87	5.76	94.10
	LSTM-RF	91.78	19.31	84.83
	CLKAN-RF	**99.60**	**1.28**	**99.05**
漂移异常	No LSTM	72.20	21.92	75.88
	No RF	97.40	72.12	53.95
	No 1D CNN	98.13	21.64	85.78
	No KAN	97.53	21.88	85.4
	TCN-KAN-RF	87.80	10.69	88.75
	LSTM-RF	89.07	29.96	77.18
	CLKAN-RF	**98.27**	**9.96**	**93.13**
卡死异常	No LSTM	86.47	17.56	83.95
	No RF	98.53	59.99	63.38
	No 1D CNN	98.53	3.28	97.40
	No KAN	98.53	2.56	97.85
	TCN-KAN-RF	97.47	5.36	95.70
	LSTM-RF	92.73	17.36	86.43
	CLKAN-RF	**100.00**	**1.84**	**98.78**

图5

异常类型	阈值类型	评估指标		
		TPR	FPR	ACC
偏置异常	静态阈值	99.46	1.40	98.92
	动态阈值	**99.60**	**1.28**	**99.05**
漂移异常	静态阈值	**98.86**	11.64	92.77
	动态阈值	98.27	**9.96**	**93.13**
卡死异常	静态阈值	**100.00**	1.96	98.67
	动态阈值	**100.00**	**1.84**	**98.78**

图6